# Московский Государственный технический университет имени Н. Э. Баумана



Лабораторная работа №4 по курсу: «Технология машинного обучения»

Работу выполнил студ	ент группы ИУ5-63
Федорова Антонина	
	Работу проверил:
Гапанюк Ю Е	

#### Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train\_test\_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кросс-валидации. Проведите эксперименты с тремя различными стратегиями кросс-валидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

Текст программы с примерами выполнения программы:

В качестве набора данных я выбрала датасет, демонстрирующий качество вина по содержанию в нем разных веществ (<a href="https://www.kaggle.com/uciml/red-wine-quality-cortez-et-al-2009/version/2">https://www.kaggle.com/uciml/red-wine-quality-cortez-et-al-2009/version/2</a>).

Эта задача будет полезна в различных ресторанах, алкогольных магазинах, а также на различных винодельнях.

Датасет состоит пока что из одного файла, но для обучения модели я разобью его на 3 части.

В моем датасете хранятся следующие данные:

- 1)fixed acidit фиксированная кислотность
- 2)volatile acidity летучая кислотность
- 3)citric acid лимонная кислота
- 4)residual sugar остаточный сахар
- 5)chlorides хлориды
- 6)free sulfur dioxide свободный диоксид серы
- 7)total sulfur dioxide общий диоксид серы
- 8)density плотность
- 9)рН водородный показатель
- 10)sulphates сульфаты
- 11)alcohol алкоголь
- 12)quality качество целевой признак оценка вина от 0 до 10 баллов (на деле от 3 до 8)

Более подробное описание этого датасета по ссылке.

```
#Импорт библиотек
```

```
import numpy as np
import pandas as pd
import seaborn as sns
from google.colab import drive
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score, precision_score
from sklearn.model_selection import cross_val_score, cross_validate
from sklearn.model_selection import KFold, RepeatedKFold, LeaveOneOut, LeavePOut
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.model_selection import learning_curve, validation_curve
```

#Монтирую гугл диск, чтобы взять оттуда датасет drive.mount("/content/gdrive", force remount=True)

Mounted at /content/gdrive

```
#Загружаю данные с гугл диска
data = pd.read_csv('/content/gdrive/My Drive/winequality-red.csv', sep=",")
```

data.head(10)

С> free total fixed volatile citric residual sulfur density chlorides sulfur acidity acidity acid sugar dioxide dioxide 7.4 0.00 1.9 11.0 34.0 0 0.70 0.076 0.9978 1 7.8 2.6 25.0 0.88 0.00 0.098 67.0 0.9968 2 7.8 0.76 0.04 2.3 0.092 15.0 54.0 0.9970 3 11.2 0.28 1.9 0.075 17.0 0.56 60.0 0.9980 4 7.4 0.70 0.00 1.9 0.076 11.0 34.0 0.9978 5 7.4 0.66 0.00 1.8 0.075 13.0 40.0 0.9978 6 7.9 0.60 0.06 1.6 0.069 15.0 59.0 0.9964 7 7.3 0.65 0.00 1.2 0.065 15.0 21.0 0.9946 8 7.8 2.0 0.58 0.02 0.073 9.0 18.0 0.9968 7.5 9 0.50 6.1 0.071 17.0 102.0 0.36 0.9978

```
E→ Bcero ctpok: 1599
fixed acidity - 0
volatile acidity - 0
citric acid - 0
residual sugar - 0
chlorides - 0
free sulfur dioxide - 0
total sulfur dioxide - 0
density - 0
pH - 0
sulphates - 0
alcohol - 0
quality - 0
```

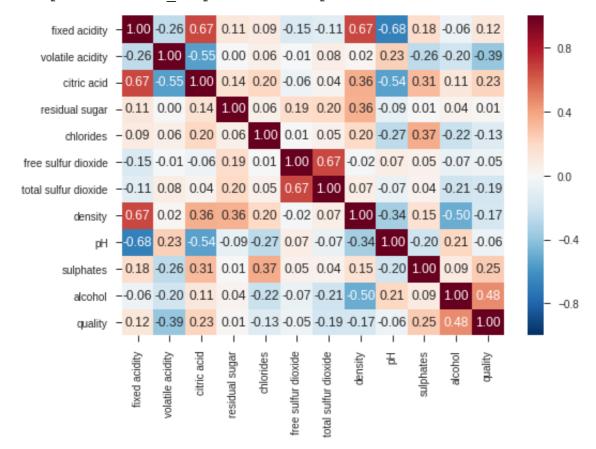
## #Типы данных значений датасета data.dtypes

С⇒	fixed acidity	float64
_	volatile acidity	float64
	citric acid	float64
	residual sugar	float64
	chlorides	float64
	free sulfur dioxide	float64
	total sulfur dioxide	float64
	density	float64
	рН	float64
	sulphates	float64
	alcohol	float64
	quality	int64
	dtype: object	

Так как нет нулевых значений, и нет никаких категориальных признаков - ничего заменять не надо. Но признаков очень много, некоторые можно убрать.

sns.heatmap(data.corr(method='pearson'), annot=True, fmt='.2f')

<matplotlib.axes. subplots.AxesSubplot at 0x7ff05ecf6438>



Исходя из этого можно сказать, что некоторые признаки будут только мешать и их стоит убрать.

```
cols_x = ['fixed acidity', 'citric acid', 'sulphates', 'alcohol']

# целевой признак
col_y = 'quality'

#разделение данных
X_train, X_test, y_train, y_test = train_test_split(data[cols_x], data[col_y], to N_train, _ = X_train.shape
N_test, _ = X_test.shape
print (N_train, N_test)

Г→ 799 800
```

## - Классификатор

Я решила использовать классификатор, так как у меня получается только есть только 6 оценок. Есть предположение, что регрессор будет прездсказывать значения, невходящие в эти 6 оценок.

```
y test.head(20)
     1429
     260
               5
     916
               5
     1141
               6
     1574
               6
     82
               5
     1038
               7
               5
     641
     56
               5
               6
     1073
     433
               5
     1575
               6
     136
               5
               3
     899
     1025
               6
     604
               6
     775
               5
               7
     1150
     1239
     293
     Name: quality, dtype: int64
```

#### Попробую сделать то же, но с 5 соседями

#### Проверка точности разными метриками

```
#5 ближайших соседей accuracy_score(y_test, KNeighborsClassifierObj5.predict(X_test)) 

□→ 0.54375
```

```
#3 ближайших соседа
accuracy score(y test, KNeighborsClassifierObj.predict(X test))
□→ 0.5175
# Конвертация целевого признака в бинарный
def convert_target_to_binary(array:np.ndarray, target:int) -> np.ndarray:
    # Если целевой признак совпадает с указанным, то 1 иначе 0
    res = [1 if x==target else 0 for x in array]
    return res
# Если целевой признак ==7,
# то будем считать этот случай 1 в бинарном признаке
bin_y_test = convert_target_to_binary(y_test, 7)
list(zip(y test, bin y test))[0:15]
\Gamma \rightarrow [(5, 0),
      (5, 0),
      (5, 0),
      (6, 0),
      (6, 0),
      (5, 0),
      (7, 1),
      (5, 0),
      (5, 0),
      (6, 0),
      (5, 0),
      (6, 0),
      (5, 0),
      (3, 0),
      (6, 0)
# Конвертация предсказанных признаков
bin_target3 = convert_target_to_binary(KNeighborsClassifierObj.predict(X_test),
bin target5 = convert target to binary(KNeighborsClassifierObj5.predict(X test),
#3 ближайших соседа
balanced_accuracy_score(bin_y_test, bin_target3)
    0.5957142857142856
\Gamma
#5 ближайших соседей
balanced accuracy score(bin y test, bin target5)
   0.6278571428571429
```

```
#3 СОСЕДО
precision_score(bin_y_test, bin_target3), recall_score(bin_y_test, bin_target3)

[ > (0.32926829268292684, 0.27)

#5 СОСЕДЕЙ
precision_score(bin_y_test, bin_target5), recall_score(bin_y_test, bin_target5)

[ > (0.4155844155844156, 0.32)
```

### **- Кросс-валидация**

scores = cross validate(KNeighborsClassifier(n neighbors=8),

```
data[cols x], data[col y], scoring=scoring,
                      cv=3, return train score=True)
[→ ;r/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   sr/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   sr/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn_for)
   sr/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   ;r/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   sr/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   ;r/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn_for)
   sr/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   sr/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   ir/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   ;r/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
   ;r/local/lib/python3.6/dist-packages/sklearn/metrics/classification.py:1143
   precision', 'predicted', average, warn for)
```

#### scores

```
score time': array([0.01546717, 0.01255178, 0.01525617]),
     'test f1': array([0.47744419, 0.51588412, 0.52858502]),
     'test precision': array([0.49122376, 0.50427431, 0.52647768]),
     'test recall': array([0.51775701, 0.53283302, 0.5480226 ]),
     'train f1': array([0.63805783, 0.64823261, 0.64068281]),
     'train_precision': array([0.63372329, 0.65771406, 0.62684221]),
     'train recall': array([0.66259398, 0.67073171, 0.66385768])}
#Kfold
scores = cross val score(KNeighborsClassifier(n neighbors=5),
                     data[cols x], data[col y],
                     cv=KFold(n splits=5))
scores
Гэ
   array([0.5
                    , 0.528125 , 0.553125 , 0.521875 , 0.52978056])
```

## - Grid Search (решетчатый поиск)

```
n_range = np.array(range(2,22,2))
tuned_parameters = [{'n_neighbors': n_range}]
tuned parameters
   [{'n neighbors': array([ 2, 4, 6, 8, 10, 12, 14, 16, 18, 20])}]
clf gs = GridSearchCV(KNeighborsClassifier(), tuned parameters, cv=5, scoring='at
clf_gs.fit(data[cols_x], data[col_y])
GridSearchCV(cv=5, error score='raise-deprecating',
           estimator=KNeighborsClassifier(algorithm='auto', leaf size=30, metr
               metric params=None, n jobs=None, n neighbors=5, p=2,
               weights='uniform'),
           fit params=None, iid='warn', n jobs=None,
           param grid=[{'n neighbors': array([ 2, 4, 6, 8, 10, 12, 14, 16,
           pre dispatch='2*n jobs', refit=True, return train score='warn',
           scoring='accuracy', verbose=0)
clf_gs.cv_results_
「→ /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fi
      warnings.warn(*warn args, **warn kwargs)
    /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fu
      warnings.warn(*warn args, **warn kwargs)
    /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fu
      warnings.warn(*warn_args, **warn_kwargs)
    /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fu
      warnings.warn(*warn args, **warn kwargs)
    /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fu
      warnings.warn(*warn args, **warn kwargs)
    /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fu
      warnings.warn(*warn_args, **warn_kwargs)
    /usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: Fu
      warnings.warn(*warn args, **warn kwargs)
    {'mean fit time': array([0.00320864, 0.0018784 , 0.00196204, 0.00184245, 0
            0.00188065, 0.00202212, 0.00205121, 0.00203662, 0.00200739]),
     'mean_score_time': array([0.00361848, 0.00244255, 0.00246744, 0.00240417,
                        0.00291009 0.00328074 0.00344324 0.0032355311
            0.0027307
```

```
0.002/00/ / 0.002/100/ 0.000200/11/ 0.000313221/ 0.000200001//
'mean test score': array([0.48968105, 0.51782364, 0.50906817, 0.53283302,
             0.53158224, 0.53033146, 0.52595372, 0.51969981, 0.52470294]),
'mean train score': array([0.83254899, 0.72529956, 0.69418839, 0.67104697
             0.63633265, 0.62429062, 0.6147541 , 0.61398714, 0.60912688]),
'param n neighbors': masked array(data=[2, 4, 6, 8, 10, 12, 14, 16, 18, 20
                        mask=[False, False, Fal
                                    False, False],
             fill value='?',
                      dtype=object),
'params': [{'n neighbors': 2},
 {'n_neighbors': 4},
 {'n neighbors': 6},
 {'n neighbors': 8},
 {'n neighbors': 10},
 {'n neighbors': 12},
 {'n neighbors': 14},
 {'n neighbors': 16},
 {'n neighbors': 18},
 {'n neighbors': 20}],
'rank_test_score': array([10, 8, 9, 2, 1, 3, 4, 5, 7, 6], dtype=:
'split0 test score': array([0.48757764, 0.5
                                                                                                , 0.50310559, 0.5341614!
             0.52484472, 0.51242236, 0.49378882, 0.46583851, 0.46583851]),
'split0_train_score': array([0.83085356, 0.72905247, 0.69616288, 0.671104]
             0.64369616, 0.63821457, 0.62098669, 0.63194988, 0.60532498]),
'split1_test_score': array([0.47663551, 0.48909657, 0.47352025, 0.51713390
             0.50155763, 0.48909657, 0.48598131, 0.48286604, 0.4953271 ]),
'split1 train score': array([0.83333333, 0.72769953, 0.7057903 , 0.679968'
             0.64319249, 0.61893584, 0.60954617, 0.62441315, 0.62206573]),
'split2 test score': array([0.52959502, 0.5482866 , 0.52336449, 0.5576324
             0.58566978, 0.58566978, 0.60124611, 0.60436137, 0.61370717]),
'split2 train score': array([0.83020344, 0.72222222, 0.68935837, 0.665884)
             0.61580595, 0.60250391, 0.60406886, 0.59937402, 0.59389671]),
'split3 test score': array([0.47169811, 0.52830189, 0.55345912, 0.5408805
             0.5408805 , 0.55345912 , 0.5408805 , 0.55345912 , 0.54716981]),
'split3_train_score': array([0.83060109, 0.72521468, 0.68618267, 0.672131]
             0.63778298, 0.62607338, 0.61436378, 0.60265418, 0.6128025 ]),
'split4 test score': array([0.48264984, 0.52365931, 0.49211356, 0.5141955
             0.50473186, 0.51104101, 0.50788644, 0.49211356, 0.50157729]),
'split4 train score': array([0.83775351, 0.72230889, 0.69344774, 0.6661460
             0.64118565, 0.63572543, 0.62480499, 0.61154446, 0.61154446),
```

#### # Лучшая модель

clf gs.best estimator

KNeighborsClassifier(algorithm='auto', leaf size=30, metric='minkowski', metric params=None, n jobs=None, n neighbors=10, p=2, weights='uniform')

```
# Лучшее значение метрики clf_gs.best_score_

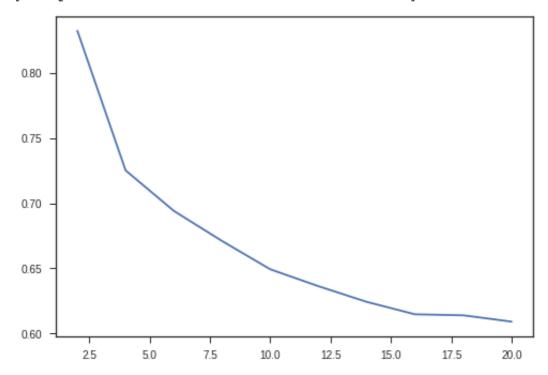
□ 0.5453408380237649

# Лучшее значение параметров clf_gs.best_params_

□ {'n_neighbors': 10}
```

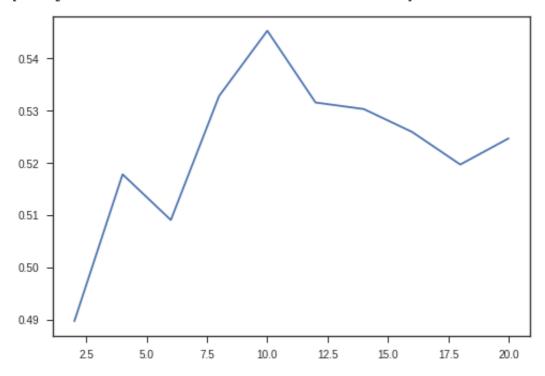
```
# Изменение качества на обучающей выборке plt.plot(n_range, clf_gs.cv_results_['mean_train_score'])
```

/usr/local/lib/python3.6/dist-packages/sklearn/utils/deprecation.py:125: F
 warnings.warn(\*warn\_args, \*\*warn\_kwargs)
[<matplotlib.lines.Line2D at 0x7ff05a828cf8>]



## # Изменение качества на тестовой выборке plt.plot(n range, clf gs.cv results ['mean test score'])

[<matplotlib.lines.Line2D at 0x7ff05a7fcb00>]



KNeighborsClassifierObjBest = KNeighborsClassifier(n\_neighbors=10)
KNeighborsClassifierObj

KNeighborsClassifierObjBest.fit(X\_train, y\_train)
KNeighborsClassifierObjBest.predict(X test)[0:20]

 $\Gamma \rightarrow \text{array}([6, 5, 6, 6, 5, 5, 7, 5, 5, 6, 5, 6, 5, 6, 5, 6, 5, 7, 6, 5])$ 

accuracy score(y test, KNeighborsClassifierObjBest.predict(X test))

□→ 0.53625

def convert\_target\_to\_binary(array:np.ndarray, target:int) -> np.ndarray:
 # Если целевой признак совпадает с указанным, то 1 иначе 0
 res = [1 if x==target else 0 for x in array]
 return res

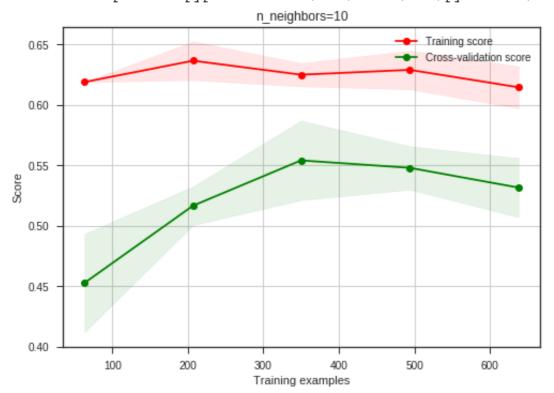
#### # Конвертация предсказанных признаков

bin\_targetBest = convert\_target\_to\_binary(KNeighborsClassifierObjBest.predict(X\_)

```
balanced accuracy score(bin y test, bin targetBest)
□→ 0.635
precision_score(bin_y test, bin_targetBest), recall_score(bin_y test, bin_targetBest)
\Gamma \rightarrow (0.40963855421686746, 0.34)
def plot_learning_curve(estimator, title, X, y, ylim=None, cv=None,
                        n jobs=None, train sizes=np.linspace(.1, 1.0, 5)):
    Generate a simple plot of the test and training learning curve.
    Parameters
    _____
    estimator: object type that implements the "fit" and "predict" methods
        An object of that type which is cloned for each validation.
    title : string
        Title for the chart.
    X : array-like, shape (n_samples, n_features)
        Training vector, where n samples is the number of samples and
        n features is the number of features.
    y : array-like, shape (n_samples) or (n_samples, n_features), optional
        Target relative to X for classification or regression;
        None for unsupervised learning.
    ylim: tuple, shape (ymin, ymax), optional
        Defines minimum and maximum yvalues plotted.
    cv : int, cross-validation generator or an iterable, optional
        Determines the cross-validation splitting strategy.
        Possible inputs for cv are:
          - None, to use the default 3-fold cross-validation,
          - integer, to specify the number of folds.
          - :term: `CV splitter`,
          - An iterable yielding (train, test) splits as arrays of indices.
        For integer/None inputs, if ``y`` is binary or multiclass,
        :class:`StratifiedKFold` used. If the estimator is not a classifier
        or if ``y`` is neither binary nor multiclass, :class:`KFold` is used.
        Refer :ref:`User Guide <cross_validation>` for the various
        cross-validators that can be used here.
    n_jobs : int or None, optional (default=None)
        Number of jobs to run in parallel.
         `None` means 1 unless in a :obj: joblib.parallel_backend context.
        ``-1`` means using all processors. See :term:`Glossary <n_jobs>`
        for more details.
    train_sizes : array-like, shape (n_ticks,), dtype float or int
        Relative or absolute numbers of training examples that will be used to
        generate the learning curve. If the dtype is float, it is regarded as a
        fraction of the maximum size of the training set (that is determined
        by the selected validation method), i.e. it has to be within (0, 1].
        Otherwise it is interpreted as absolute sizes of the training sets.
        Note that for classification the number of samples usually have to
```

```
be big enough to contain at least one sample from each class.
        (default: np.linspace(0.1, 1.0, 5))
    plt.figure()
    plt.title(title)
    if ylim is not None:
        plt.ylim(*ylim)
    plt.xlabel("Training examples")
    plt.ylabel("Score")
    train_sizes, train_scores, test_scores = learning_curve(
        estimator, X, y, cv=cv, n_jobs=n_jobs, train_sizes=train_sizes)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test_scores_mean = np.mean(test_scores, axis=1)
    test_scores_std = np.std(test_scores, axis=1)
    plt.grid()
    plt.fill_between(train_sizes, train_scores_mean - train_scores_std,
                     train_scores_mean + train_scores_std, alpha=0.1,
                     color="r")
    plt.fill between(train sizes, test scores mean - test scores std,
                     test_scores_mean + test_scores_std, alpha=0.1, color="g")
    plt.plot(train_sizes, train_scores_mean, 'o-', color="r"
             label="Training score")
    plt.plot(train sizes, test scores mean, 'o-', color="g",
             label="Cross-validation score")
    plt.legend(loc="best")
    return plt
plot learning curve(KNeighborsClassifier(n neighbors=10), 'n neighbors=10',
```

X train, y train, cv=StratifiedKFold(n splits=5))



```
def plot validation curve(estimator, title, X, y,
                          param name, param range, cv,
                          scoring="accuracy"):
    train_scores, test_scores = validation_curve(
        estimator, X, y, param name=param name, param range=param range,
        cv=cv, scoring=scoring, n_jobs=1)
    train_scores_mean = np.mean(train_scores, axis=1)
    train_scores_std = np.std(train_scores, axis=1)
    test scores mean = np.mean(test scores, axis=1)
    test scores std = np.std(test scores, axis=1)
    plt.title(title)
    plt.xlabel(param name)
    plt.ylabel("Score")
    plt.ylim(0.0, 1.1)
    lw = 2
    plt.plot(param range, train scores mean, label="Training score",
                 color="darkorange", lw=lw)
    plt.fill between(param range, train scores mean - train scores std,
                     train scores mean + train scores std, alpha=0.2,
                     color="darkorange", lw=lw)
    plt.plot(param range, test scores mean, label="Cross-validation score",
                 color="navy", lw=lw)
    plt.fill between(param range, test scores mean - test scores std,
                     test scores mean + test scores std, alpha=0.2,
                     color="navy", lw=lw)
    plt.legend(loc="best")
    return plt
```

 $\begin{tabular}{ll} \hline \begin{tabular}{ll} \hline \end{tabular} \end{tabular$ 

