Московский Государственный технический университет имени Н. Э. Баумана



Лабораторная работа № 5 по курсу: «Технология машинного обучения»

Работу выполнил студо	ент группы ИУ5-63
Федорова Антонина	
	Работу проверил:
Гапанюк Ю Е	

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите 1) одну из линейных моделей, 2) SVM и 3) дерево решений. Оцените качество моделей с помощью трех подходящих для задачи метрик. Сравните качество полученных моделей.
- 5. Произведите для каждой модели подбор одного гиперпараметра с использованием GridSearchCV и кросс-валидации.
- 6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4

Текст программы с примерами выполнения программы:

#Импорт библиотек

from google.colab import drive

import numpy as np

import pandas as pd

from sklearn.model_selection import train_test_split

from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier

from sklearn.metrics import accuracy score, balanced accuracy score

from sklearn.metrics import precision_score, recall_score

from sklearn.linear_model import SGDClassifier

from sklearn.svm import SVC

from sklearn.model_selection import KFold

from sklearn.model_selection import GridSearchCV

from sklearn.tree import DecisionTreeClassifier

import seaborn as sns

from sklearn.preprocessing import StandardScaler

import matplotlib.pyplot as plt

% matplotlib inline

sns.set(style=«ticks")

data.head(5)

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	рН
0	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51
1	7.8	0.88	0.00	2.6	0.098	25.0	67.0	0.9968	3.20
2	7.8	0.76	0.04	2.3	0.092	15.0	54.0	0.9970	3.26
3	11.2	0.28	0.56	1.9	0.075	17.0	60.0	0.9980	3.16
4	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51

```
cols_x = ['fixed acidity', 'citric acid', 'sulphates', 'alcohol']
# целевой признак
col y = 'quality'
scaler = StandardScaler()
X = \text{scaler.fit transform}(\text{data}[\text{cols } x])
#разделение данных на тестовую и обучающую выборки
X_train, X_test, y_train, y_test = train_test_split(X, data[col_y], test_size = 0.5, random_state
= 11)
N train, = X train.shape
N_{\text{test}}, \underline{\ } = X_{\text{test.shape}}
print (N train, N test)
grad = SGDClassifier().fit(X train, y train)
target_grad = grad.predict(X_test)
def convert_target_to_binary(array:np.ndarray, target:int) -> np.ndarray:
  # Если целевой признак совпадает с указанным, то 1 иначе 0
  res = [1 \text{ if } x = target else 0 \text{ for } x \text{ in array}]
  return res
# Если целевой признак == 6,
# то будем считать этот случай 1 в бинарном признаке
bin_y_test = convert_target_to_binary(y_test, 6)
list(zip(y_test, bin_y_test))[0:15]
# Конвертация предсказанных признаков
bin_target_grad = convert_target_to_binary(target_grad, 6)
```

```
ac_grad = accuracy_score(y_test, target_grad)
bas_grad = balanced_accuracy_score(bin_y_test, bin_target_grad)
rec_grad = recall_score(bin_y_test, bin_target_grad)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}''''.format(ac_grad, bas_grad, rec_grad))

accuracy_score: 0.52
balanced_accuracy_score: 0.5708821930573891
recall_score: 0.42024539877300615
```

Обучение с помощью SVM

recall score: 0.5552147239263804

```
[ ] svmcl = SVC(kernel='rbf', gamma=0.5, C=1.0).fit(X_train, y_train)
[ ] target_svm = svmcl.predict(X_test)
```

Оценка качества метода опорных векторов

Обучение с помощью деревьев принятия решений

```
[ ] dtcl = DecisionTreeClassifier(random_state=1, max_depth = 20).fit(X_train, y_train)

[ ] dtcl

[ ] DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=20, max_features=None, max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0, presort=False, random_state=1, splitter='best')

[ ] target_dtc = dtcl.predict(X_test)
```

Оценка качества классификации методом деревьев принятия решений

```
# Конвертация предсказанных признаков
bin_target_dtc = convert_target_to_binary(target_dtc, 6)

[] ac_dtc = accuracy_score(y_test, target_dtc)
bas_dtc = balanced_accuracy_score(bin_y_test, bin_target_dtc)
rec_dtc = recall_score(bin_y_test, bin_target_dtc)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_dtc, bas_dtc, rec_dtc))

[] accuracy_score: 0.545
balanced_accuracy_score: 0.6081644275322927
recall_score: 0.5306748466257669
```

Подбор гиперпараметра с использованием GridSearchCV и кроссвалидации

Для градиентного спуска

Обучение с подобранным параметром

```
[ ] grad_gs.best_estimator_.fit(X_train, y_train)
  target_grad_gs = grad_gs.best_estimator_.predict(X_test)
```

Проверка качества модели

recall_score: 0.5552147239263804

```
# Конвертация предсказанных признаков
        bin_target_grad_gs = convert_target_to_binary(target_grad_gs, 6)
[ ] #Новая модель
        ac_grad_gs = accuracy_score(y_test, target_grad_gs)
       bas_grad_gs = accuracy_score(y_test, target_grad_gs)
bas_grad_gs = balanced_accuracy_score(bin_y_test, bin_target_grad_gs)
rec_grad_gs = recall_score(bin_y_test, bin_target_grad_gs)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_grad_gs, bas_grad_gs, rec_grad_gs))
 accuracy_score: 0.4975
       balanced_accuracy_score: 0.5237374129585048
       recall score: 0.2331288343558282
[ ] #Старая модель
       ac_grad = accuracy_score(y_test, target_grad)
bas_grad = balanced_accuracy_score(bin_y_test, bin_target_grad)
rec_grad = recall_score(bin_y_test, bin_target_grad)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_grad, bas_grad, rec_grad))

¬ accuracy score: 0.52

       balanced_accuracy_score: 0.5708821930573891
       recall_score: 0.42024539877300615
Для SVM
[ ] tuned_parameters_svm = [{'gamma': n_range}]
[ ] svm_gs = GridSearchCV(SVC(), tuned_parameters_svm, cv=KFold(n_splits=5), scoring='accuracy')
       svm_gs.fit(data[cols_x], data[col_y])
[ ] svm_gs.best_params_

    ['gamma': 0.050100000000000006}

Обучение с подобранным параметром
[ ] svm_gs.best_estimator_.fit(X_train, y_train)
        target_svm_gs = svm_gs.best_estimator_.predict(X_test)
Проверка качества модели
[ ] # Конвертация предсказанных признаков
        bin_target_svm_gs = convert_target_to_binary(target_svm_gs, 6)
[ ] #Новая модель
       ac_svm_gs = accuracy_score(y_test, target_svm_gs)
bas_svm_gs = balanced_accuracy_score(bin_y_test, bin_target_svm_gs)
rec_svm_gs = recall_score(bin_y_test, bin_target_svm_gs)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_svm_gs, bas_svm_gs, rec_svm_gs))
 accuracy_score: 0.5725
       balanced_accuracy_score: 0.6037444021640651
       recall_score: 0.5766871165644172
[ ] #Старая модель
        ac_svm = accuracy_score(y_test, target_svm)
        bas_svm = balanced_accuracy_score(bin_y_test, bin_target_svm)
rec_svm = recall_score(bin_y_test, bin_target_svm)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_svm, bas_svm, rec_svm))

→ accuracy_score: 0.60125

       balanced accuracy score: 0.6309828893893505
```

Для деревьев принятия решений

```
[ ] n_range_dtc = np.array(range(1,100,10))
    tuned_parameters_dtc = [{'max_depth': n_range_dtc}]
    tuned_parameters_dtc

[ {'max_depth': array([ 1, 11, 21, 31, 41, 51, 61, 71, 81, 91])}]

[ ] dtc_gs = GridSearchCV(DecisionTreeClassifier(), tuned_parameters_dtc, cv=KFold(n_splits=10), scoring='accuracy')
    dtc_gs.fit(X_train, y_train)

[ ] dtc_gs.best_params_
[ -> {'max_depth': 1}
```

Обучение с подобранным параметром

```
[ ] dtc_gs.best_estimator_.fit(X_train, y_train)
    target_dtc_gs = dtc_gs.best_estimator_.predict(X_test)
```

Проверка качества модели

```
# Конвертация предсказанных признаков
         bin_target_dtc_gs = convert_target_to_binary(target_dtc_gs, 6)
        wholeds Modells
ac_dtc_gs = accuracy_score(y_test, target_dtc_gs)
bas_dtc_gs = balanced_accuracy_score(bin_y_test, bin_target_dtc_gs)
rec_dtc_gs = recall_score(bin_y_test, bin_target_dtc_gs)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_dtc_gs, bas_dtc_gs, rec_dtc_gs))
 caccuracy_score: 0.55125
balanced_accuracy_score: 0.5797869586601434
recall_score: 0.49079754601226994
[ ] #CTapas Modenb
ac_dtc = accuracy_score(y_test, target_dtc)
bas_dtc = balanced_accuracy_score(bin_y_test, bin_target_dtc)
rec_dtc = recall_score(bin_y_test, bin_target_dtc)
print('''accuracy_score: {0}
balanced_accuracy_score: {1}
recall_score: {2}'''.format(ac_dtc, bas_dtc, rec_dtc))
 c accuracy_score: 0.545
balanced_accuracy_score: 0.6081644275322927
recall_score: 0.5306748466257669
  from sklearn.externals.six import StringIO
  from IPython.display import Image
  from sklearn.tree import export_graphviz
  import pydotplus
  dot_data = StringIO()
  export_graphviz(dtcl, out_file=dot_data,
                                  filled=True, rounded=True,
                                 special_characters=True)
  graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
  Image(graph.create_png())
```

